

# Espaces de Hilbert à noyaux reproduisants (RKHS)

## 1 Motivations

On considère un problème d'estimation :

$$\forall i \in \llbracket 1, n \rrbracket, \quad y_i = f(x_i, \beta) \quad \text{avec } \beta \in \mathbb{R}^p, \quad x_i \in \mathbb{R}^p, \quad y_i \in \mathbb{R}.$$

$$\text{On pose : } X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix} \in \mathbb{R}^{n \times p} \text{ et } Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n.$$

- Estimation linéaire :  $f(x, \beta) = x^T \beta$ .

On utilise la régularisation de Tikhonov :  $\min_{\beta \in \mathbb{R}^p} \frac{1}{2} \|X\beta - Y\|_2^2 + \frac{\lambda}{2} \|\beta\|_2^2$ .

On a la CN1 (condition nécessaire d'ordre 1) :  $\nabla f(\beta) = 0$ .

$$\Leftrightarrow X^T(X\beta - Y) + \lambda\beta = 0.$$

$$\Leftrightarrow X^T X\beta + \lambda\beta = X^T Y.$$

$$\Leftrightarrow (X^T X + \lambda I_p)\beta = X^T Y.$$

$$\Leftrightarrow \hat{\beta} = (X^T X + \lambda I_p)^{-1} X^T Y.$$

Donc la prédiction sera :  $\hat{Y} = X\hat{\beta} = X(X^T X + \lambda I_p)^{-1} X^T Y$ .

→ Complexité en  $\mathcal{O}(p^2 n)$  ou  $\mathcal{O}(n^2 p)$  (selon  $X^T X$  ou  $XX^T$ ).

- Estimation quadratique :  $f(x, \beta, \theta) = x^T \theta x + x\beta = \sum_{k=0}^p x_k \beta_k + \sum_{k,l} x_k x_l \theta_{kl}$ .  
2 inconnues :  $\beta \in \mathbb{R}^p$  et  $\theta \in \mathbb{R}^{p \times p}$ .

$$\text{Soit } \tilde{\beta} = \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_p \\ \theta_{11} \\ \vdots \\ \theta_{pp} \end{pmatrix} \in \mathbb{R}^{p+p^2}, \quad \tilde{x}_i = \begin{pmatrix} x_i^1 \\ \vdots \\ x_i^p \\ x_i^1 x_i^1 \\ \vdots \\ x_i^p x_i^p \end{pmatrix}, \quad \tilde{X} = \begin{pmatrix} \tilde{x}_1^T \\ \vdots \\ \tilde{x}_n^T \end{pmatrix}.$$

→ Complexité en  $\mathcal{O}(np^4)$  ou  $\mathcal{O}(n^2 p^2)$  (selon  $\tilde{X}^T \tilde{X}$  ou  $\tilde{X} \tilde{X}^T$ ).

1. Est-ce qu'il existe une fonction qui permet de rester sur une résolution linéaire tout en augmentant la dimension du modèle ?  
→ Oui, mais (quasi) jamais explicitée.
2. Peut-on s'épargner la complexité du modèle en gardant la complexité des données initiales ?  
→ Oui, avec un noyau.

$$\text{Ici, } \phi_i : \mathbb{R}^p \longrightarrow \mathbb{R}^{p+p^2}$$

$$x_i \longmapsto \begin{pmatrix} x_i^1 \\ \vdots \\ x_i^p \\ x_i^1 x_i^1 \\ \vdots \\ x_i^p x_i^p \end{pmatrix} = \tilde{x}_i$$

Si on se ramène à  $\tilde{x}_i^T \tilde{x}_j = (1 + x_i^T x_j)^2$ , on n'a plus que des produits de  $(x_i^T x_j)$ , donc une complexité en  $\mathcal{O}(np^2)$ .

On définit une application  $k : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$  tel que  $k(x_i, x_j) = (1 + x_i^T x_j)^2$ .

**Méthode générale :**

On cherche à prédire  $y \in \mathbb{R}$  avec un prédicteur  $x \in \mathbb{R}^p$ .

- Afin d'appliquer l'approche de régularisation de Tikhonov, on va chercher  $\phi : \mathbb{R}^p \longrightarrow \mathbb{R}^d$  avec  $d$  à préciser ( $d \in \{\mathbb{N}, \infty\}$ ).
- On va appliquer la régularisation aux données transformées  $(\phi(x_i))_{i \in \llbracket 1, n \rrbracket}$  comme prédicteur.
- On va être amené à construire un noyau  $K \in \mathcal{M}_p(\mathbb{R})$  avec  $K_{ij} = \langle \phi(x_i), \phi(x_j) \rangle$ .

$$\begin{aligned} \rightarrow \text{On va chercher } k : \mathbb{R}^p \times \mathbb{R}^p &\longrightarrow \mathbb{R} \\ (x_i, x_j) &\longmapsto \langle \phi(x_i), \phi(x_j) \rangle \end{aligned}$$

## 2 Espaces de Hilbert à noyau reproduisant

Soit  $\mathcal{H}$  un espace de Hilbert (muni du produit scalaire  $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ ) et  $X \subset \mathcal{H}$ .

### Propriété

Soit  $\phi : X \longrightarrow \mathcal{H}$ .

On définit  $k : X \times X \longrightarrow \mathbb{R}$   
 $(x, x') \longmapsto \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}$

Soit  $K$  la matrice définie par :

$\forall i, j \in \llbracket 1, n \rrbracket, \quad K_{ij} = k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle_{\mathcal{H}}$ .

Alors  $K$  est symétrique positive.

► Soit  $\alpha \in \mathbb{R}^n, (x_i) \in X^n$ .

$$\begin{aligned} \text{On a : } \alpha^T K \alpha &= \sum_{i,j} \alpha_i \alpha_j k(x_i, x_j) \\ &= \sum_{i,j} \alpha_i \alpha_j \langle \phi(x_i), \phi(x_j) \rangle_{\mathcal{H}} \\ &= \left\langle \sum_i \alpha_i \phi(x_i), \sum_j \alpha_j \phi(x_j) \right\rangle_{\mathcal{H}} \\ &= \|\mathcal{Z}\|_{\mathcal{H}}^2 \geq 0 \quad \text{avec } \mathcal{Z} = \sum_i \alpha_i \phi(x_i) \end{aligned}$$

### Définition

Un *noyau défini positif* (ou *noyau*) est une application symétrique :

$k : X \times X \longrightarrow \mathbb{R}$  telle que  $\forall (x_i) \in X^n$ , la matrice  $K \in \mathcal{M}_n(\mathbb{R})$  définie par  $K_{ij} = k(x_i, x_j)$  est symétrique positive.

### Propriété

Soit  $(k_i)_{i \in J}$  une famille de noyaux.

- i) Soit  $(\alpha_i, \alpha_j) \in \mathbb{R}_+^2$ . Alors  $\alpha_i k_i + \alpha_j k_j$  est un noyau.
- ii) Si  $\exists \lim_{p \rightarrow +\infty} k_p(x, x'), \forall (x, x') \in X^2$ , alors  $k$  la limite simple de  $(k_p)_{p \in J}$  est un noyau.
- iii) Le produit (terme à terme)  $k_i k_j$  est un noyau.  
 $k(x, x') = k_i(x, x') k_j(x, x')$

### Exercice :

1. Noyau linéaire :  $X = \mathbb{R}^p$  et  $\forall (x, x') \in X^2, \quad k(x, x') = x^T x'$ .
2. Noyau polynomial :  $X = \mathbb{R}^p$  et  $\forall (x, x') \in X^2, \quad k(x, x') = (1 + x^T x')^d$ .
3. Noyau exponentiel :  $X = \mathbb{R}^p$  et  $\forall (x, x') \in X^2, \quad k(x, x') = \exp(-\frac{\|x - x'\|^2}{2\sigma^2})$ .  
avec  $\sigma > 0$ .

Montrer que les noyaux polynomial et exponentiel sont des noyaux.

### Correction :

1. Noyeau par définition.
  2. Par produit de noyaux.
  3.  $k(x, x') = \exp(-\frac{\|x-x'\|^2}{2\sigma^2}) = \exp(-\frac{\|x\|^2}{2\sigma^2}) \exp(\frac{x^T x'}{\sigma^2}) \exp(-\frac{\|x'\|^2}{2\sigma^2}) = k_1(x, x') k_2(x, x')$ .  
avec  $k_1(x, x') = \exp(-\frac{\|x\|^2}{2\sigma^2}) \exp(-\frac{\|x'\|^2}{2\sigma^2})$  et  $k_2(x, x') = \exp(\frac{x^T x'}{\sigma^2})$ .
- $k_1(x, x') = \langle \phi(x), \phi(x') \rangle$  avec  $\phi(x) = \exp(-\frac{\|x\|^2}{2\sigma^2})$ .  $k_1$  noyau (proposition 1).  
 $k_2(x, x') = \sum_{i=0}^{+\infty} \frac{1}{i!} \left( \frac{x^T x'}{\sigma^2} \right)^i$ .  $k_2$  noyau (proposition 2).

### Théorème de Moore-Aronszajn

Soit  $k$  un noyau,  $k : X \times X \longrightarrow \mathbb{R}$ .

Alors il existe un espace de Hilbert  $\mathcal{H}$  et une application  $\phi : X \longrightarrow \mathcal{H}$  tel que  
 $\forall (x, x') \in X^2, \quad k(x, x') = \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}$ .

► Soit  $\mathcal{H} = \{f : X \rightarrow \mathbb{R} \text{ tel que } \exists n \in \mathbb{N}, \exists (\alpha_j)_{j \in \llbracket 1, n \rrbracket} \in \mathbb{R}^n, \exists (x_j)_{j \in \llbracket 1, n \rrbracket} \in X^n, f(\cdot) = \sum_{j=1}^n \alpha_j k(\cdot, x_j)\}$ .

*Texte manquant.*

## 3 Applications

### 3.1 Régularisation de Tikhonov

Le problème s'écrit :

$$(P) : \min_{\beta \in \mathbb{R}^p} \frac{1}{2} \|X\beta - Y\|_2^2 + \frac{\lambda}{2} \|\beta\|_2^2 \quad (1)$$

Soit le RKHS de noyau reproduisant le noyau linéaire.

$f \in \mathcal{H} : \sum_{i=1}^m \alpha_i k(\cdot, x_i) = k(\cdot, \sum_{i=1}^m \alpha_i x_i)$  (par linéarité du noyau).  
 $f(x) = x^T \tilde{x}$  avec  $\tilde{x} = \sum_{i=1}^m \alpha_i x_i$ .

$$f(\tilde{x}) = \tilde{x}^T \tilde{x} = \|\tilde{x}\|_2^2.$$

$$\begin{aligned} \text{et } \|f\|_{\mathcal{H}}^2 &= \langle f, f \rangle_{\mathcal{H}} \\ &= \left\langle \sum_{i=1}^m \alpha_i k(\cdot, x_i), \sum_{j=1}^m \alpha_j k(\cdot, x_j) \right\rangle_{\mathcal{H}} \\ &= \langle k(\cdot, \tilde{x}), k(\cdot, \tilde{x}) \rangle_{\mathcal{H}} \\ &= k(\tilde{x}, \tilde{x}) \\ &= \|\tilde{x}\|_2^2 \end{aligned}$$

Donc (P) s'écrit :

$$(P) : \min_{f \in \mathcal{H}} \frac{1}{2} \sum_{i=1}^m (f(x_i) - y_i)^2 + \frac{\lambda}{2} \|f\|_{\mathcal{H}}^2 \quad (2)$$

D'après le théorème du représentant,  $\hat{f} \in \text{Vect}(k(\cdot, x_i))_{i \in \llbracket 1, m \rrbracket}$ .

$$\hat{f} = \sum_{i=1}^m \alpha_i k(\cdot, x_i).$$

On pose  $K = [k(x_i, x_j)]_{i,j \in \llbracket 1, m \rrbracket} \in \mathcal{M}_m(\mathbb{R})$ .

$$\begin{aligned} \text{On a : } \|\hat{f}\|_{\mathcal{H}}^2 &= \left\langle \sum_{i=1}^m \alpha_i k(\cdot, x_i), \sum_{j=1}^m \alpha_j k(\cdot, x_j) \right\rangle_{\mathcal{H}} \\ &= \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j k(x_i, x_j) \\ &= \alpha^T K \alpha \end{aligned}$$

$$\text{et } f(x_i) = \sum_{j=1}^m \alpha_j k(x_i, x_j) = [K\alpha]_i.$$

$$\text{D'où (P')} \Leftrightarrow \min_{\alpha \in \mathbb{R}^m} \frac{1}{2} \|Y - K\alpha\|_2^2 + \frac{\lambda}{2} \alpha^T K \alpha.$$

On a la CN1 :  $\nabla f(\alpha) = 0$

$$\begin{aligned} &\Leftrightarrow -K^T(Y - K\alpha) + \lambda K\alpha = 0 \\ &\Leftrightarrow K^T K\alpha + \lambda K\alpha = K^T Y \\ &\Leftrightarrow (K^T K + \lambda K)\alpha = K^T Y \\ &\Leftrightarrow \hat{\alpha} = (K^T K + \lambda K)^{-1} K^T Y \end{aligned}$$

Et la prédiction :  $K\hat{\alpha} = K(K^T K + \lambda K)^{-1} K^T Y$ .